



UNIVERSIDADE ESTADUAL DE CAMPINAS

Análise do Treinamento de Redes Neurais Profundas no Paradigma de Aprendizado por Reforço Através do Plano de Informação

Arthur Fernandes

Sumário

Introdução

Fundamentação

Metodologia


Resultados

Conclusão

Referências


Introdução

- Supervisionado
- Não Supervisionado
- Por Reforço (RL)



Introdução

Uso de redes profundas em RL (Mnih *et al.*, 2015)




Introdução

Recompensa acumulada




Introdução

Plano de Informação (Shwartz-Ziv; Tishby, 2017)



Introdução

Information Bottleneck e RL (Lu et al., 2020; Fan e Li, 2022)



Objetivos

Geral: aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação

Específicos:

- Investigar a relação entre o fluxo de informação na rede profunda e o processo de aprendizado do agente em RL;
- Analisar trajetórias no plano de informação e identificar possíveis estágios do aprendizado;
- Propor uma variação do plano de informação para RL, de forma a não depender de um rótulo;
- Avaliar o efeito de topologias distintas no plano de informação, considerando diferentes cenários em RL.

Fundamentação

Redes Neurais Artificiais

- *Perceptron*
- *Multi-Layer Perceptron*

Aprendizado por Reforço


- Introdução ao RL
- Funções Valor
- Função de Aproximação
- *Actor-Critic*
- *Proximal Policy Optimization*

Teoria da Informação

- Entropia, Divergência KL e Informação Mútua
- *Information Bottleneck*
- Plano de Informação

Fundamentação – Redes Neurais Artificiais


Perceptron (Haykin, 2009)



$$y = f \left(\sum_{i=1}^n (x_i w_i) + b \right) = f(\mathbf{w}^T \mathbf{x})$$


Fundamentação – Redes Neurais Artificiais

Multi-Layer Perceptron (MLP) (Haykin, 2009)



Fundamentação – Aprendizado por Reforço

Introdução ao Aprendizado por Reforço (Russel *et al.*, 2010)




Fundamentação – Aprendizado por Reforço

Funções Valor e Função de Aproximação (Sutton; Barto, 1998)

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} \mid S = s \right]$$


$$q_{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} \mid S = s, A = a \right]$$




$$\hat{Q}_{\theta}(s, a) = \theta^T \mathbf{f}(s, a)$$

Fundamentação – Aprendizado por Reforço

Actor-Critic



Actor Network




Critic Network

Fundamentação – Aprendizado por Reforço

Proximal Policy Optimization (Schulman *et al.*, 2017)

$$\mathcal{L}^{CLI} = \mathbb{E} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{old}}(a|s)} \hat{A}_k \right] = \mathbb{E} \left[r_k(\theta) \hat{A}_k \right]$$

$$\mathcal{L}^{CLIP} = \mathbb{E} \left[\min \left(r_k(\theta) \hat{A}_k, \text{clip}(r_k(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_k \right) \right]$$



Fundamentação – Teoria da Informação

Entropia, Divergência KL e Informação Mútua (Cover; Thomas, 2006)


$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x)$$

$$D(p||q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)}$$

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$


Fundamentação – Teoria da Informação

Information Bottleneck (Tishby; Zaslavsky, 2015)



Fundamentação – Teoria da Informação


Plano de Informação (Shwartz-Ziv; Tishby, 2017)



Fundamentação – Teoria da Informação



Plano de Informação: abordagem alternativa para o caso RL

Usamos $\hat{Y}$ para ao invés do rótulo Y



Metodologia

Agente, Estimação de Informação Mútua e Ambientes




Metodologia – Agente

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologias alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

Cada experimento foi executado por 10^6 passos.



$(n_X, 32, 32, n_Y)$



Stable-Baselines3

Metodologia – Informação Mútua

A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov *et al.* (2004).


Pequenas flutuações e ruídos na curva de IM estimada são inerentes ao processo de estimação.

Foi analisado o fluxo entre todas as camadas, não só utilizando entrada e saída real.

$$\hat{I}(X, h_2) \times \hat{I}(h_2, \hat{Y}) \quad \hat{I}(h_1, h_2) \times \hat{I}(h_2, \hat{Y})$$

Metodologia – Informação Mútua

KNN (Kraskov *et al.*, 2004)




$$\hat{I}(X, Y) = \psi(k) - \frac{1}{N} \sum_{i=1}^N [\psi(n_{x_i}) + \psi(n_{y_i})] + \psi(N)$$

Metodologia – Ambientes

Ambientes usados: *Pendulum*, *Acrobot*, *MountainCar* e *CartPole*.

Observação	Min	Max
Posição do carrinho	-4.8	4.8
Velocidade do carrinho	$-\infty$	∞
Ângulo da haste	$\sim -24^\circ$	$\sim 24^\circ$
Velocidade angular da haste	$-\infty$	∞



Empurrar o carrinho para $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

Critérios para finalização do episódio:






- Se a posição do carrinho ultrapassar a região $(-2.4, 2.4)$;
- Se o ângulo da haste sair da região $(-12^\circ, 12^\circ)$;
- Se a recompensa acumulada atingir o limite de 500.

Resultados


Quadro de experimentos

Experimento	Ambiente	Topologia
I	CartPole	$(n_X, 32, 32, n_Y)$
II	Acrobot	$(n_X, 32, 32, n_Y)$
III	Pendulum	$(n_X, 32, 32, n_Y)$
IV	MountainCar	$(n_X, 32, 32, n_Y)$
V	CartPole	$(n_X, 32, n_Y)$
VI	CartPole	$(n_X, 32, 32, 32, n_Y)$
VII	Acrobot	$(n_X, 32, n_Y)$
VIII	Acrobot	$(n_X, 32, 32, 32, n_Y)$






Resultados – Experimento II



Resultados – Experimento VIII



Resultados – Experimento IV



Conclusão

- Fases distintas no aprendizado;
- Generalização requer investigação aprofundada;
- O plano de informação como métrica alternativa;
- Tendências no plano de informação podem indicar uma potencial convergência do aprendizado.

Referências

COVER, T. M.; THOMAS, Joy A. **Elements of information theory**. 2nd ed ed. Hoboken, N.J: Wiley-Interscience, 2006.

FAN, Jiameng; LI, Wenchao. DRIBO: Robust Deep Reinforcement Learning via Multi-View Information Bottleneck. *In*: CHAUDHURI, Kamalika *et al.* (orgs.). : Proceedings of Machine Learning Research.PMLR, 17 jul. 2022. Disponível em: <<https://proceedings.mlr.press/v162/fan22b.html>>

HAYKIN, Simon S. **Neural networks and learning machines**. 3. ed ed. New York Munich: Prentice-Hall, 2009.

KRASKOV, Alexander; STÖGBAUER, Harald; GRASSBERGER, Peter. Estimating mutual information. **Physical Review E**, v. 69, n. 6, jun. 2004.

LU, Xingyu *et al.* **Dynamics Generalization via Information Bottleneck in Deep Reinforcement Learning**. arXiv, , 3 ago. 2020. Disponível em: <<http://arxiv.org/abs/2008.00614>>. Acesso em: 30 jan. 2025

MNIH, Volodymyr *et al.* Human-level control through deep reinforcement learning. **Nature**, v. 518, n. 7540, p. 529–533, 26 fev. 2015.

Referências

RUSSELL, Stuart J.; NORVIG, Peter; DAVIS, Ernest. **Artificial intelligence: a modern approach**. 3rd ed ed. Upper Saddle River: Prentice Hall, 2010.

SCHULMAN, John *et al.* **Proximal Policy Optimization Algorithms**. arXiv, , 28 ago. 2017. Disponível em: <<http://arxiv.org/abs/1707.06347>>. Acesso em: 5 abr. 2024

SHWARTZ-ZIV, Ravid; TISHBY, Naftali. **Opening the Black Box of Deep Neural Networks via Information**. arXiv, , 29 abr. 2017. Disponível em: <<http://arxiv.org/abs/1703.00810>>. Acesso em: 21 set. 2024

SUTTON, Richard S.; BARTO, Andrew G. **Reinforcement learning: an introduction**. Cambridge, Mass: MIT Press, 1998.

TISHBY, Naftali; ZASLAVSKY, Noga. Deep learning and the information bottleneck principle. *In*: 2015 IEEE INFORMATION THEORY WORKSHOP (ITW). **2015 IEEE Information Theory Workshop (ITW)**. Jerusalem, Israel: IEEE, abr. 2015. Disponível em: <<http://ieeexplore.ieee.org/document/7133169>>. Acesso em: 12 jun. 2025

Fundamentação – Aprendizado por Reforço

Definições de Aprendizado por Reforço (Sutton; Barto, 1998)

$\mathcal{S}$	Conjunto de Estados	s	estado	s'	estado futuro
$\mathcal{A}$	Conjunto de Ações	a	ação	a'	ação futura
$\mathcal{R}$	Conjunto de Recompensas	r	recompensa		

π	Política	$\pi : \mathcal{S} \rightarrow \mathcal{A}$
R	Função de Recompensa	$R : \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{R}$

Metodologia – Agente

\item a partir da inicialização aleatória das redes, ocorre a interação do agente com o ambiente, registrando as transições até o \textit{buffer} atingir o número de passos definido \$(2048)\$;

\item em seguida, a interação com o episódio atual é pausada e inicia-se a atualização das redes ator e crítico pelo número de épocas definido \$(10)\$. Durante esta etapa, também ocorre o processo de estimação da informação mútua após cada época de atualização;

\item Terminadas as épocas, o \textit{buffer} é reiniciado e se continua o processo de interação do agente com o ambiente, agora com a nova política.

Parâmetro	Valor
Semente Aleatória (<i>seed</i>)	0
Número de Passos (por iteração)	2048
Tamanho do Lote (<i>batch size</i>)	64
Número de Épocas	10

Trabalhos Futuros

- Realizar uma análise detalhada da evolução da IM entre as camadas e a saída da rede $\hat{Y}$ em tarefas de aprendizado supervisionado bem estabelecidas (exemplo MNIST);
- Expansão dos experimentos para ambientes mais complexos, incluindo uma gama mais ampla de ambientes da biblioteca Gymnasium;
- Investigar o impacto de diferentes topologias de rede nas métricas de IM e na performance do agente;
- Conduzir uma comparação sobre como a otimização de hiperparâmetros afeta a trajetória do agente no plano de informação;

Trabalhos Futuros

- Explorar a possibilidade de incorporar métricas de IM diretamente no processo de otimização de hiperparâmetros;
- Comparar com outras técnicas de RL como *Deep Q-Network* (DQN), *Soft Actor-Critic* (SAC) e *Twin Delayed* DDPG (TD3);
- Avaliar o uso do plano de informação como métrica de convergência do aprendizado do agente.