



UNICAMP

UNIVERSIDADE ESTADUAL DE CAMPINAS

Análise do Treinamento de Redes Neurais Profundas no Paradigma de Aprendizado por Reforço Através do Plano de Informação

Arthur Fernandes
Prof. Dr. Denis Fantinato

SUMÁRIO

Introdução

Fundamentação

Metodologia

Resultados

Conclusão

Referências

INTRODUÇÃO

- Supervisionado

INTRODUÇÃO

- Supervisionado
- Não Supervisionado

INTRODUÇÃO

- Supervisionado
- Não Supervisionado
- Por Reforço (RL)

INTRODUÇÃO

- Supervisionado
- Não Supervisionado
- Por Reforço (RL)




Figura 1. Paradigmas de aprendizado: supervisionado, não supervisionado e por reforço.

INTRODUÇÃO

USO DE REDES PROFUNDAS EM RL MNIH ET AL. [1]

INTRODUÇÃO

USO DE REDES PROFUNDAS EM RL MNIH ET AL. [1]




Figura 2. Arquitetura DQN aplicada a jogos Atari [1].

INTRODUÇÃO

RECOMPENSA ACUMULADA

INTRODUÇÃO

RECOMPENSA ACUMULADA

INTRODUÇÃO

PLANO DE INFORMAÇÃO E INFORMATION BOTTLENECK SHWARTZ-ZIV AND TISHBY [2]

INTRODUÇÃO

PLANO DE INFORMAÇÃO E INFORMATION BOTTLENECK SHWARTZ-ZIV AND TISHBY [2]




Figura 3. Plano de Informação na formulação clássica [2].

INTRODUÇÃO

INFORMATION BOTTLENECK E RL FAN AND LI [3]

INTRODUÇÃO

INFORMATION BOTTLENECK E RL FAN AND LI [3]




Figura 4. Abordagem clássica do Information Bottleneck [2].

OBJETIVOS

OBJETIVOS

Geral: aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

OBJETIVOS

Geral: aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

Específicos:

- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente;

OBJETIVOS

Geral: aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

Específicos:

- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente;
- Analisar trajetórias no plano de informação e identificar possíveis estágios do aprendizado;

OBJETIVOS

Geral: aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

Específicos:

- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente;
- Analisar trajetórias no plano de informação e identificar possíveis estágios do aprendizado;
- Propor variação do plano de informação para RL sem depender de rótulo explícito;

OBJETIVOS

Geral: aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

Específicos:

- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente;
- Analisar trajetórias no plano de informação e identificar possíveis estágios do aprendizado;
- Propor variação do plano de informação para RL sem depender de rótulo explícito;
- Avaliar efeito de topologias distintas em diferentes ambientes.

FUNDAMENTAÇÃO

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**

- ▶ Perceptron
- ▶ MLP

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron
 - ▶ MLP
- **Aprendizado por Reforço:**

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**

- ▶ Perceptron
- ▶ MLP

- **Aprendizado por Reforço:**

- ▶ Introdução ao RL

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**

- ▶ Perceptron
- ▶ MLP

- **Aprendizado por Reforço:**

- ▶ Introdução ao RL
- ▶ Funções Valor

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron
 - ▶ MLP
- **Aprendizado por Reforço:**
 - ▶ Introdução ao RL
 - ▶ Funções Valor
 - ▶ Função da Aproximação

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron
 - ▶ MLP
- **Aprendizado por Reforço:**
 - ▶ Introdução ao RL
 - ▶ Funções Valor
 - ▶ Função da Aproximação
 - ▶ Actor-Critic

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron
 - ▶ MLP
- **Aprendizado por Reforço:**
 - ▶ Introdução ao RL
 - ▶ Funções Valor
 - ▶ Função da Aproximação
 - ▶ Actor-Critic
 - ▶ Proximal Policy Optimization

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron
 - ▶ MLP
- **Aprendizado por Reforço:**
 - ▶ Introdução ao RL
 - ▶ Funções Valor
 - ▶ Função da Aproximação
 - ▶ Actor-Critic
 - ▶ Proximal Policy Optimization
- **Teoria da Informação:**

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron
 - ▶ MLP
- **Aprendizado por Reforço:**
 - ▶ Introdução ao RL
 - ▶ Funções Valor
 - ▶ Função da Aproximação
 - ▶ Actor-Critic
 - ▶ Proximal Policy Optimization
- **Teoria da Informação:**
 - ▶ Entropia, Divergência KL e Informação Mútua

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron
 - ▶ MLP
- **Aprendizado por Reforço:**
 - ▶ Introdução ao RL
 - ▶ Funções Valor
 - ▶ Função da Aproximação
 - ▶ Actor-Critic
 - ▶ Proximal Policy Optimization
- **Teoria da Informação:**
 - ▶ Entropia, Divergência KL e Informação Mútua
 - ▶ Information Bottleneck

FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
 - ▶ Perceptron
 - ▶ MLP
- **Aprendizado por Reforço:**
 - ▶ Introdução ao RL
 - ▶ Funções Valor
 - ▶ Função da Aproximação
 - ▶ Actor-Critic
 - ▶ Proximal Policy Optimization
- **Teoria da Informação:**
 - ▶ Entropia, Divergência KL e Informação Mútua
 - ▶ Information Bottleneck
 - ▶ Plano de Informação

FUNDAMENTAÇÃO

REDES NEURAIS ARTIFICIAIS

FUNDAMENTAÇÃO

REDES NEURAIS ARTIFICIAIS




Figura 5. Perceptron [4].

FUNDAMENTAÇÃO

REDES NEURAIS ARTIFICIAIS

FUNDAMENTAÇÃO

REDES NEURAIS ARTIFICIAIS




Figura 6. Multi-Layer Perceptron (MLP) [4].

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO




Figura 7. Dinâmica de Aprendizado por Reforço [5].

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO




Figura 7. Dinâmica de Aprendizado por Reforço [5].

$$(s_k, a_k, s_{k+1}, r_{k+1})$$

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s \right]$$

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s \right]$$

$$q_{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s, A = a \right]$$

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s \right]$$

$$q_{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s, A = a \right]$$

$$\hat{Q}_{\theta}(s, a) = \boldsymbol{\theta}^T \mathbf{f}(s, a)$$

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s \right]$$

$$q_{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s, A = a \right]$$

$$\hat{Q}_{\theta}(s, a) = \boldsymbol{\theta}^T \mathbf{f}(s, a)$$

Diretório quebrado

Figura 8. Plano de Informação [2].

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO




Figura 9. Actor network

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO




Figura 9. Actor network




Figura 10. Critic network

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

$$\mathcal{L}^{CLI} = \mathbb{E} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \hat{A}_k \right] = \mathbb{E} \left[r_k(\theta) \hat{A}_k \right]$$

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

$$\mathcal{L}^{CLI} = \mathbb{E} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \hat{A}_k \right] = \mathbb{E} \left[r_k(\theta) \hat{A}_k \right]$$

$$\mathcal{L}^{CLIP} = \mathbb{E} \left[\min \left(r_k(\theta) \hat{A}_k, \text{clip}(r_k(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_k \right) \right]$$

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

$$\mathcal{L}^{CLI} = \mathbb{E} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \hat{A}_k \right] = \mathbb{E} \left[r_k(\theta) \hat{A}_k \right]$$

$$\mathcal{L}^{CLIP} = \mathbb{E} \left[\min \left(r_k(\theta) \hat{A}_k, \text{clip}(r_k(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_k \right) \right]$$





Figura 11. Proximal Policy Optimization [6].

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x)$$

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x)$$

$$D(p||q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)}$$

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x)$$

$$D(p||q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)}$$

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)}$$

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO




Figura 12. Fluxo da Informação - caso supervisionado.

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO




Figura 13. Plano de Informação [2].

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

Usamos $\hat{Y}$ para aproximar ao invés do rótulo Y .

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

Usamos $\hat{Y}$ para aproximar ao invés do rótulo Y .




Figura 14. Fluxo da Informação - caso por reforço.

METODOLOGIA

AGENTE, ESTIMAÇÃO DE INFORMAÇÃO MÚTUA E AMBIENTES

METODOLOGIA

AGENTE, ESTIMAÇÃO DE INFORMAÇÃO MÚTUA E AMBIENTES



Figura 15

METODOLOGIA

AGENTE, ESTIMAÇÃO DE INFORMAÇÃO MÚTUA E AMBIENTES



Figura 15



Figura 16

METODOLOGIA

AGENTE

METODOLOGIA

AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

METODOLOGIA

AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologia alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

METODOLOGIA

AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologia alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

Cada experimento foi executado por 10^6 passos.


METODOLOGIA

AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologia alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

Cada experimento foi executado por 10^6 passos.



$$(n_X, 32, 32, n_Y)$$

Figura 17. Topologia de rede utilizada nos experimentos.

METODOLOGIA

AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologia alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

Cada experimento foi executado por 10^6 passos.




Figura 17. Topologia de rede utilizada nos experimentos.



Figura 18. Implementação com Stable-Baselines3.

METODOLOGIA

INFORMAÇÃO MÚTUA

- A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov et al. [7];

METODOLOGIA

INFORMAÇÃO MÚTUA

- A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov et al. [7];
- Pequenas flutuações e ruídos na curva de IM estimada são inerentes ao processo de estimação;

METODOLOGIA

INFORMAÇÃO MÚTUA

- A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov et al. [7];
- Pequenas flutuações e ruídos na curva de IM estimada são inerentes ao processo de estimação;
- Foi analisado o fluxo entre todas as camadas, não só utilizando entrada e saída real.

METODOLOGIA

INFORMAÇÃO MÚTUA

- A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov et al. [7];
- Pequenas flutuações e ruídos na curva de IM estimada são inerentes ao processo de estimação;
- Foi analisado o fluxo entre todas as camadas, não só utilizando entrada e saída real.

$$\hat{I}(X; h_2) \times \hat{I}(h_2; \hat{Y})$$

$$\hat{I}(h_1; h_2) \times \hat{I}(h_2; \hat{Y})$$

METODOLOGIA

ESTIMAÇÃO DE INFORMAÇÃO MÚTUA

METODOLOGIA

ESTIMAÇÃO DE INFORMAÇÃO MÚTUA




Figura 19. Estimação por KNN conforme Kraskov et al. [7].

METODOLOGIA

ESTIMAÇÃO DE INFORMAÇÃO MÚTUA




Figura 19. Estimação por KNN conforme Kraskov et al. [7].

$$\hat{I}(X; Y) = \psi(k) - \frac{1}{N} \sum_{i=1}^N [\psi(n_{x_i}) + \psi(n_{y_i}) + \psi(N)]$$

METODOLOGIA

AMBIENTES

METODOLOGIA

AMBIENTES

Tabela 1. Observações do ambiente *CartPole*

Observação	Min	Max
Posição do carrinho	-4.8	4.8
Velocidade do carrinho	$-\infty$	∞
Ângulo da haste	$\sim -24^\circ$	$\sim 24^\circ$
Velocidade angular da haste	$-\infty$	∞

Fonte: Adaptado de Towers et al. [8].

METODOLOGIA

AMBIENTES

Tabela 1. Observações do ambiente *CartPole*

Observação	Min	Max
Posição do carrinho	-4.8	4.8
Velocidade do carrinho	$-\infty$	∞
Ângulo da haste	$\sim -24^\circ$	$\sim 24^\circ$
Velocidade angular da haste	$-\infty$	∞

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

METODOLOGIA

AMBIENTES

gif eventual

Tabela 1. Observações do ambiente *CartPole*

Observação	Min	Max
Posição do carrinho	-4.8	4.8
Velocidade do carrinho	$-\infty$	∞
Ângulo da haste	$\sim -24^\circ$	$\sim 24^\circ$
Velocidade angular da haste	$-\infty$	∞

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

METODOLOGIA

AMBIENTES

gif eventual

Tabela 1. Observações do ambiente *CartPole*

Observação	Min	Max
Posição do carrinho	-4.8	4.8
Velocidade do carrinho	$-\infty$	∞
Ângulo da haste	$\sim -24^\circ$	$\sim 24^\circ$
Velocidade angular da haste	$-\infty$	∞

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

Critérios para finalização do episódio:

METODOLOGIA

AMBIENTES

gif eventual

Tabela 1. Observações do ambiente *CartPole*

Observação	Min	Max
Posição do carrinho	-4.8	4.8
Velocidade do carrinho	$-\infty$	∞
Ângulo da haste	$\sim -24^\circ$	$\sim 24^\circ$
Velocidade angular da haste	$-\infty$	∞

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

CrITÉRIOS para finalização do episódio:

- Se a posição do carrinho ultrapassar a região $(-2.4, 2, 4)$;

METODOLOGIA

AMBIENTES

gif eventual

Tabela 1. Observações do ambiente *CartPole*

Observação	Min	Max
Posição do carrinho	-4.8	4.8
Velocidade do carrinho	$-\infty$	∞
Ângulo da haste	$\sim -24^\circ$	$\sim 24^\circ$
Velocidade angular da haste	$-\infty$	∞

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

CrITÉRIOS para finalização do episódio:

- Se a posição do carrinho ultrapassar a região $(-2.4, 2, 4)$;
- Se o ângulo da haste sair da região $(-12^\circ, 12^\circ)$;

METODOLOGIA

AMBIENTES

gif eventual

Tabela 1. Observações do ambiente *CartPole*

Observação	Min	Max
Posição do carrinho	-4.8	4.8
Velocidade do carrinho	$-\infty$	∞
Ângulo da haste	$\sim -24^\circ$	$\sim 24^\circ$
Velocidade angular da haste	$-\infty$	∞

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

CrITÉRIOS para finalização do episódio:

- Se a posição do carrinho ultrapassar a região $(-2.4, 2, 4)$;
- Se o ângulo da haste sair da região $(-12^\circ, 12^\circ)$;
- Se a recompensa acumulada atingir o limite de 500.

RESULTADOS PRINCIPAIS

RESULTADOS PRINCIPAIS

Tabela 2. Tabela de experimentos

Experimento	Ambiente	Topologia
I	CartPole	$(n_X, 32, 32, n_Y)$
II	Acrobot	$(n_X, 32, 32, n_Y)$
III	Pendulum	$(n_X, 32, 32, n_Y)$
IV	MountainCar	$(n_X, 32, 32, n_Y)$
V	CartPole	$(n_X, 32, n_Y)$
VI	CartPole	$(n_X, 32, 32, 32, n_Y)$
VII	Acrobot	$(n_X, 32, n_Y)$
VIII	Acrobot	$(n_X, 32, 32, 32, n_Y)$

RESULTADOS

EXPERIMENTO II

RESULTADOS

EXPERIMENTO II




Figura 20. Topologia de rede utilizada nos experimentos.

RESULTADOS

EXPERIMENTO II




Figura 20. Topologia de rede utilizada nos experimentos.




Figura 21. Implementação com Stable-Baselines3.

CONCLUSÃO

CONCLUSÃO

- Fases distintas no aprendizado;

CONCLUSÃO

- Fases distintas no aprendizado;
- Generalização requer investigação aprofundada;

CONCLUSÃO

- Fases distintas no aprendizado;
- Generalização requer investigação aprofundada;
- O plano de informação como métrica alternativa;

CONCLUSÃO

- Fases distintas no aprendizado;
- Generalização requer investigação aprofundada;
- O plano de informação como métrica alternativa;
- Tendências no plano de informação podem indicar uma potencial convergência do aprendizado.

REFERÊNCIAS I

- [1] V. Mnih et al., “Human-level control through deep reinforcement learning,” en, *Nature*, vol. 518, no. 7540, pp. 529–533, Feb. 2015.
- [2] R. Shwartz-Ziv and N. Tishby, *Opening the Black Box of Deep Neural Networks via Information*, arXiv:1703.00810 [cs], Apr. 2017.
- [3] J. Fan and W. Li, “DRIBO: Robust Deep Reinforcement Learning via Multi-View Information Bottleneck,” in *Proceedings of the 39th International Conference on Machine Learning*, K. Chaudhuri, S. Jegelka, L. Song, C. Szepesvari, G. Niu, and S. Sabato, Eds., ser. Proceedings of Machine Learning Research, vol. 162, PMLR, Jul. 2022, pp. 6074–6102.
- [4] S. S. Haykin, *Neural networks and learning machines*, en, 3. ed. New York Munich: Prentice-Hall, 2009.
- [5] S. J. Russell, P. Norvig, and E. Davis, *Artificial intelligence: a modern approach* (Prentice Hall series in artificial intelligence), 3rd ed. Upper Saddle River: Prentice Hall, 2010.
- [6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, *Proximal Policy Optimization Algorithms*, arXiv:1707.06347 [cs], Aug. 2017.
- [7] A. Kraskov, H. Stögbauer, and P. Grassberger, “Estimating mutual information,” *Physical Review E*, vol. 69, no. 6, Jun. 2004, Publisher: American Physical Society (APS).
- [8] M. Towers et al., *Gymnasium*, Mar. 2023.