



**UNICAMP**

UNIVERSIDADE ESTADUAL DE CAMPINAS

# **Análise do Treinamento de Redes Neurais Profundas no Paradigma de Aprendizado por Reforço Através do Plano de Informação**

Arthur Fernandes  
Prof. Dr. Denis Fantinato

# SUMÁRIO

**Introdução**

**Fundamentação**

**Metodologia**

**Resultados**

**Conclusão**

**Referências**

# INTRODUÇÃO

- Supervisionado

# INTRODUÇÃO


- Supervisionado
- Não Supervisionado

# INTRODUÇÃO

- Supervisionado
- Não Supervisionado
- Por Reforço (RL)

# INTRODUÇÃO

- Supervisionado
- Não Supervisionado
- Por Reforço (RL)




**Figura 1.** Paradigmas de aprendizado: supervisionado, não supervisionado e por reforço.

# INTRODUÇÃO

USO DE REDES PROFUNDAS EM RL MNIH ET AL. [1]

# INTRODUÇÃO

USO DE REDES PROFUNDAS EM RL MNIH ET AL. [1]



**Figura 2.** Arquitetura DQN aplicada a jogos Atari [1].



# INTRODUÇÃO

RECOMPENSA ACUMULADA

# INTRODUÇÃO


RECOMPENSA ACUMULADA

# INTRODUÇÃO

PLANO DE INFORMAÇÃO E INFORMATION BOTTLENECK SHWARTZ-ZIV AND TISHBY [2]

# INTRODUÇÃO

PLANO DE INFORMAÇÃO E INFORMATION BOTTLENECK SHWARTZ-ZIV AND TISHBY [2]




**Figura 3.** Plano de Informação na formulação clássica [2].

# INTRODUÇÃO

INFORMATION BOTTLENECK E RL FAN AND LI [3]

# INTRODUÇÃO

INFORMATION BOTTLENECK E RL FAN AND LI [3]



**Figura 4.** Abordagem clássica do Information Bottleneck [2].

# OBJETIVOS

## OBJETIVOS

**Geral:** aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.



## OBJETIVOS

**Geral:** aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

**Específicos:**

- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente;

## OBJETIVOS

**Geral:** aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

**Específicos:**

- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente;
- Analisar trajetórias no plano de informação e identificar possíveis estágios do aprendizado;

## OBJETIVOS

**Geral:** aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

**Específicos:**

- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente;
- Analisar trajetórias no plano de informação e identificar possíveis estágios do aprendizado;
- Propor variação do plano de informação para RL sem depender de rótulo explícito;

## OBJETIVOS

**Geral:** aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.

**Específicos:**

- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente;
- Analisar trajetórias no plano de informação e identificar possíveis estágios do aprendizado;
- Propor variação do plano de informação para RL sem depender de rótulo explícito;
- Avaliar efeito de topologias distintas em diferentes ambientes.

# FUNDAMENTAÇÃO

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
  - ▶ Perceptron

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**

- ▶ Perceptron
- ▶ MLP



# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
  - ▶ Perceptron
  - ▶ MLP
- **Aprendizado por Reforço:**

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**

- ▶ Perceptron
- ▶ MLP

- **Aprendizado por Reforço:**

- ▶ Introdução ao RL

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**

- ▶ Perceptron
- ▶ MLP

- **Aprendizado por Reforço:**

- ▶ Introdução ao RL
- ▶ Funções Valor

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
  - ▶ Perceptron
  - ▶ MLP
- **Aprendizado por Reforço:**
  - ▶ Introdução ao RL
  - ▶ Funções Valor
  - ▶ Função da Aproximação

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
  - ▶ Perceptron
  - ▶ MLP
- **Aprendizado por Reforço:**
  - ▶ Introdução ao RL
  - ▶ Funções Valor
  - ▶ Função da Aproximação
  - ▶ Actor-Critic

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
  - ▶ Perceptron
  - ▶ MLP
- **Aprendizado por Reforço:**
  - ▶ Introdução ao RL
  - ▶ Funções Valor
  - ▶ Função da Aproximação
  - ▶ Actor-Critic
  - ▶ Proximal Policy Optimization

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
  - ▶ Perceptron
  - ▶ MLP
- **Aprendizado por Reforço:**
  - ▶ Introdução ao RL
  - ▶ Funções Valor
  - ▶ Função da Aproximação
  - ▶ Actor-Critic
  - ▶ Proximal Policy Optimization
- **Teoria da Informação:**

# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
  - ▶ Perceptron
  - ▶ MLP
- **Aprendizado por Reforço:**
  - ▶ Introdução ao RL
  - ▶ Funções Valor
  - ▶ Função da Aproximação
  - ▶ Actor-Critic
  - ▶ Proximal Policy Optimization
- **Teoria da Informação:**
  - ▶ Entropia, Divergência KL e Informação Mútua



# FUNDAMENTAÇÃO

- **Redes Neurais Artificiais:**
  - ▶ Perceptron
  - ▶ MLP
- **Aprendizado por Reforço:**
  - ▶ Introdução ao RL
  - ▶ Funções Valor
  - ▶ Função da Aproximação
  - ▶ Actor-Critic
  - ▶ Proximal Policy Optimization
- **Teoria da Informação:**
  - ▶ Entropia, Divergência KL e Informação Mútua
  - ▶ Information Bottleneck

# FUNDAMENTAÇÃO


- **Redes Neurais Artificiais:**
  - ▶ Perceptron
  - ▶ MLP
- **Aprendizado por Reforço:**
  - ▶ Introdução ao RL
  - ▶ Funções Valor
  - ▶ Função da Aproximação
  - ▶ Actor-Critic
  - ▶ Proximal Policy Optimization
- **Teoria da Informação:**
  - ▶ Entropia, Divergência KL e Informação Mútua
  - ▶ Information Bottleneck
  - ▶ Plano de Informação

# FUNDAMENTAÇÃO

## REDES NEURAIS ARTIFICIAIS

# FUNDAMENTAÇÃO

## REDES NEURAIS ARTIFICIAIS




**Figura 5.** Perceptron [4].

# FUNDAMENTAÇÃO

## REDES NEURAIS ARTIFICIAIS

# FUNDAMENTAÇÃO

## REDES NEURAIS ARTIFICIAIS




**Figura 6.** Multi-Layer Perceptron (MLP) [4].

# FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO



**Figura 7.** Dinâmica de Aprendizado por Reforço [5].

$$(s_k, a_k, s_{k+1}, r_{k+1})$$



# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s \right]$$

# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s \right]$$

$$q_{\pi}(s, a) = \mathbb{E}_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s, A = a \right]$$

# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s \right]$$

$$q_{\pi}(s, a) = \mathbb{E}_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s, A = a \right]$$

$$\hat{Q}_{\theta}(s, a) = \boldsymbol{\theta}^T \mathbf{f}(s, a)$$

# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO

$$v_{\pi}(s) = \mathbb{E}_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s \right]$$

$$q_{\pi}(s, a) = \mathbb{E}_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k r_{k+1} | S = s, A = a \right]$$

$$\hat{Q}_{\theta}(s, a) = \boldsymbol{\theta}^T \mathbf{f}(s, a)$$

Diretório quebrado


**Figura 8.** Plano de Informação [2].

# FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO

# FUNDAMENTAÇÃO


## APRENDIZADO POR REFORÇO




**Figura 9.** Actor network

# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO



**Figura 9.** Actor network



**Figura 10.** Critic network

# FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO



# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO

$$\mathcal{L}^{CLI} = \mathbb{E} \left[ \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \hat{A}_k \right] = \mathbb{E} \left[ r_k(\theta) \hat{A}_k \right]$$

# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO

$$\mathcal{L}^{CLI} = \mathbb{E} \left[ \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \hat{A}_k \right] = \mathbb{E} \left[ r_k(\theta) \hat{A}_k \right]$$



$$\mathcal{L}^{CLIP} = \mathbb{E} \left[ \min \left( r_k(\theta) \hat{A}_k, \text{clip}(r_k(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_k \right) \right]$$

# FUNDAMENTAÇÃO

## APRENDIZADO POR REFORÇO

$$\mathcal{L}^{CLI} = \mathbb{E} \left[ \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \hat{A}_k \right] = \mathbb{E} \left[ r_k(\theta) \hat{A}_k \right]$$

$$\mathcal{L}^{CLIP} = \mathbb{E} \left[ \min \left( r_k(\theta) \hat{A}_k, \text{clip}(r_k(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_k \right) \right]$$



**Figura 11.** Proximal Policy Optimization [6].

# FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

# FUNDAMENTAÇÃO

## TEORIA DA INFORMAÇÃO

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x)$$

# FUNDAMENTAÇÃO

## TEORIA DA INFORMAÇÃO

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x)$$

$$D(p||q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)}$$

# FUNDAMENTAÇÃO

## TEORIA DA INFORMAÇÃO

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x)$$

$$D(p||q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)}$$

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)}$$


# FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO



# FUNDAMENTAÇÃO

## TEORIA DA INFORMAÇÃO




**Figura 12.** Fluxo da Informação - caso supervisionado.

# FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

# FUNDAMENTAÇÃO

## TEORIA DA INFORMAÇÃO



**Figura 13.** Plano de Informação [2].

# FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO

# FUNDAMENTAÇÃO


## TEORIA DA INFORMAÇÃO

Usamos  $\hat{Y}$  para aproximar ao invés do rótulo  $Y$ .

# FUNDAMENTAÇÃO

## TEORIA DA INFORMAÇÃO

Usamos  $\hat{Y}$  para aproximar ao invés do rótulo  $Y$ .



**Figura 14.** Fluxo da Informação - caso por reforço.

# METODOLOGIA

AGENTE, ESTIMAÇÃO DE INFORMAÇÃO MÚTUA E AMBIENTES

# METODOLOGIA

AGENTE, ESTIMAÇÃO DE INFORMAÇÃO MÚTUA E AMBIENTES



**Figura 15**



# METODOLOGIA

AGENTE, ESTIMAÇÃO DE INFORMAÇÃO MÚTUA E AMBIENTES



**Figura 15**



**Figura 16**

# METODOLOGIA

AGENTE

# METODOLOGIA

## AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

# METODOLOGIA

## AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologia alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

# METODOLOGIA

## AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologia alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

Cada experimento foi executado por  $10^6$  passos.


# METODOLOGIA

## AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologia alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

Cada experimento foi executado por  $10^6$  passos.



$$(n_X, 32, 32, n_Y)$$

**Figura 17.** Topologia de rede utilizada nos experimentos.


# METODOLOGIA

## AGENTE

Topologia padrão: duas camadas intermediárias com 32 neurônios.

Topologia alternativas: uma camada intermediária com 32 neurônios; e três camadas intermediárias com 32 neurônios.

Cada experimento foi executado por  $10^6$  passos.



**Figura 17.** Topologia de rede utilizada nos experimentos.



**Figura 18.** Implementação com Stable-Baselines3.

# METODOLOGIA

## INFORMAÇÃO MÚTUA

- A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov et al. [7];



# METODOLOGIA

## INFORMAÇÃO MÚTUA

- A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov et al. [7];
- Pequenas flutuações e ruídos na curva de IM estimada são inerentes ao processo de estimação;

# METODOLOGIA

## INFORMAÇÃO MÚTUA

- A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov et al. [7];
- Pequenas flutuações e ruídos na curva de IM estimada são inerentes ao processo de estimação;
- Foi analisado o fluxo entre todas as camadas, não só utilizando entrada e saída real.

# METODOLOGIA

## INFORMAÇÃO MÚTUA

- A biblioteca NPEET foi utilizada para a estimação da IM, o método é baseado em Kraskov et al. [7];
- Pequenas flutuações e ruídos na curva de IM estimada são inerentes ao processo de estimação;
- Foi analisado o fluxo entre todas as camadas, não só utilizando entrada e saída real.

$$\hat{I}(X; h_2) \times \hat{I}(h_2; \hat{Y})$$


$$\hat{I}(h_1; h_2) \times \hat{I}(h_2; \hat{Y})$$

# METODOLOGIA

## ESTIMAÇÃO DE INFORMAÇÃO MÚTUA

# METODOLOGIA


## ESTIMAÇÃO DE INFORMAÇÃO MÚTUA



**Figura 19.** Estimação por KNN conforme Kraskov et al. [7].

# METODOLOGIA

## ESTIMAÇÃO DE INFORMAÇÃO MÚTUA



**Figura 19.** Estimação por KNN conforme Kraskov et al. [7].

$$\hat{I}(X; Y) = \psi(k) - \frac{1}{N} \sum_{i=1}^N [\psi(n_{x_i}) + \psi(n_{y_i}) + \psi(N)]$$

# METODOLOGIA

AMBIENTES

# METODOLOGIA

## AMBIENTES

**Tabela 1.** Observações do ambiente *CartPole*

| Observação                  | Min              | Max             |
|-----------------------------|------------------|-----------------|
| Posição do carrinho         | $-4.8$           | $4.8$           |
| Velocidade do carrinho      | $-\infty$        | $\infty$        |
| Ângulo da haste             | $\sim -24^\circ$ | $\sim 24^\circ$ |
| Velocidade angular da haste | $-\infty$        | $\infty$        |

Fonte: Adaptado de Towers et al. [8].



# METODOLOGIA

## AMBIENTES

**Tabela 1.** Observações do ambiente *CartPole*

| Observação                  | Min              | Max             |
|-----------------------------|------------------|-----------------|
| Posição do carrinho         | $-4.8$           | $4.8$           |
| Velocidade do carrinho      | $-\infty$        | $\infty$        |
| Ângulo da haste             | $\sim -24^\circ$ | $\sim 24^\circ$ |
| Velocidade angular da haste | $-\infty$        | $\infty$        |

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para  $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

# METODOLOGIA

## AMBIENTES

gif eventual

**Tabela 1.** Observações do ambiente *CartPole*

| Observação                  | Min              | Max             |
|-----------------------------|------------------|-----------------|
| Posição do carrinho         | $-4.8$           | $4.8$           |
| Velocidade do carrinho      | $-\infty$        | $\infty$        |
| Ângulo da haste             | $\sim -24^\circ$ | $\sim 24^\circ$ |
| Velocidade angular da haste | $-\infty$        | $\infty$        |

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para  $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

# METODOLOGIA

## AMBIENTES

gif eventual

**Tabela 1.** Observações do ambiente *CartPole*

| Observação                  | Min              | Max             |
|-----------------------------|------------------|-----------------|
| Posição do carrinho         | $-4.8$           | $4.8$           |
| Velocidade do carrinho      | $-\infty$        | $\infty$        |
| Ângulo da haste             | $\sim -24^\circ$ | $\sim 24^\circ$ |
| Velocidade angular da haste | $-\infty$        | $\infty$        |

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para  $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

Critérios para finalização do episódio:

# METODOLOGIA

## AMBIENTES

gif eventual

**Tabela 1.** Observações do ambiente *CartPole*

| Observação                  | Min              | Max             |
|-----------------------------|------------------|-----------------|
| Posição do carrinho         | $-4.8$           | $4.8$           |
| Velocidade do carrinho      | $-\infty$        | $\infty$        |
| Ângulo da haste             | $\sim -24^\circ$ | $\sim 24^\circ$ |
| Velocidade angular da haste | $-\infty$        | $\infty$        |

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para  $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

CrITÉRIOS para finalização do episódio:

- Se a posição do carrinho ultrapassar a região  $(-2.4, 2, 4)$ ;

# METODOLOGIA

## AMBIENTES

gif eventual

**Tabela 1.** Observações do ambiente *CartPole*

| Observação                  | Min              | Max             |
|-----------------------------|------------------|-----------------|
| Posição do carrinho         | $-4.8$           | $4.8$           |
| Velocidade do carrinho      | $-\infty$        | $\infty$        |
| Ângulo da haste             | $\sim -24^\circ$ | $\sim 24^\circ$ |
| Velocidade angular da haste | $-\infty$        | $\infty$        |

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para  $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

CrITÉRIOS para finalização do episódio:

- Se a posição do carrinho ultrapassar a região  $(-2.4, 2, 4)$ ;
- Se o ângulo da haste sair da região  $(-12^\circ, 12^\circ)$ ;

# METODOLOGIA

## AMBIENTES

gif eventual

**Tabela 1.** Observações do ambiente *CartPole*

| Observação                  | Min              | Max             |
|-----------------------------|------------------|-----------------|
| Posição do carrinho         | $-4.8$           | $4.8$           |
| Velocidade do carrinho      | $-\infty$        | $\infty$        |
| Ângulo da haste             | $\sim -24^\circ$ | $\sim 24^\circ$ |
| Velocidade angular da haste | $-\infty$        | $\infty$        |

Fonte: Adaptado de Towers et al. [8].

Empurrar o carrinho para  $\begin{cases} 0 : \text{esquerda} \\ 1 : \text{direita} \end{cases}$

CrITÉRIOS para finalização do episódio:

- Se a posição do carrinho ultrapassar a região  $(-2.4, 2, 4)$ ;
- Se o ângulo da haste sair da região  $(-12^\circ, 12^\circ)$ ;
- Se a recompensa acumulada atingir o limite de 500.

## RESULTADOS PRINCIPAIS

## RESULTADOS PRINCIPAIS

**Tabela 2.** Tabela de experimentos

| Experimento | Ambiente    | Topologia                |
|-------------|-------------|--------------------------|
| I           | CartPole    | $(n_X, 32, 32, n_Y)$     |
| II          | Acrobot     | $(n_X, 32, 32, n_Y)$     |
| III         | Pendulum    | $(n_X, 32, 32, n_Y)$     |
| IV          | MountainCar | $(n_X, 32, 32, n_Y)$     |
| V           | CartPole    | $(n_X, 32, n_Y)$         |
| VI          | CartPole    | $(n_X, 32, 32, 32, n_Y)$ |
| VII         | Acrobot     | $(n_X, 32, n_Y)$         |
| VIII        | Acrobot     | $(n_X, 32, 32, 32, n_Y)$ |




# RESULTADOS

## EXPERIMENTO II

# RESULTADOS


## EXPERIMENTO II




**Figura 20.** Topologia de rede utilizada nos experimentos.

# RESULTADOS

## EXPERIMENTO II



**Figura 20.** Topologia de rede utilizada nos experimentos.



**Figura 21.** Implementação com Stable-Baselines3.

## CONCLUSÃO

## CONCLUSÃO

- Fases distintas no aprendizado;

## CONCLUSÃO

- Fases distintas no aprendizado;
- Generalização requer investigação aprofundada;

## CONCLUSÃO

- Fases distintas no aprendizado;
- Generalização requer investigação aprofundada;
- O plano de informação como métrica alternativa;

## CONCLUSÃO

- Fases distintas no aprendizado;
- Generalização requer investigação aprofundada;
- O plano de informação como métrica alternativa;
- Tendências no plano de informação podem indicar uma potencial convergência do aprendizado.



## REFERÊNCIAS I

- [1] V. Mnih et al., “Human-level control through deep reinforcement learning,” en, *Nature*, vol. 518, no. 7540, pp. 529–533, Feb. 2015.
- [2] R. Shwartz-Ziv and N. Tishby, *Opening the Black Box of Deep Neural Networks via Information*, arXiv:1703.00810 [cs], Apr. 2017.
- [3] J. Fan and W. Li, “DRIBO: Robust Deep Reinforcement Learning via Multi-View Information Bottleneck,” in *Proceedings of the 39th International Conference on Machine Learning*, K. Chaudhuri, S. Jegelka, L. Song, C. Szepesvari, G. Niu, and S. Sabato, Eds., ser. Proceedings of Machine Learning Research, vol. 162, PMLR, Jul. 2022, pp. 6074–6102.
- [4] S. S. Haykin, *Neural networks and learning machines*, en, 3. ed. New York Munich: Prentice-Hall, 2009.
- [5] S. J. Russell, P. Norvig, and E. Davis, *Artificial intelligence: a modern approach* (Prentice Hall series in artificial intelligence), 3rd ed. Upper Saddle River: Prentice Hall, 2010.
- [6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, *Proximal Policy Optimization Algorithms*, arXiv:1707.06347 [cs], Aug. 2017.
- [7] A. Kraskov, H. Stögbauer, and P. Grassberger, “Estimating mutual information,” *Physical Review E*, vol. 69, no. 6, Jun. 2004, Publisher: American Physical Society (APS).
- [8] M. Towers et al., *Gymnasium*, Mar. 2023.