



UNICAMP

Universidade Estadual de Campinas

Análise do Treinamento de Redes Neurais Profundas no Paradigma de Aprendizado por Reforço Através do Plano de Informação

Arthur Fernandes
Prof. Dr. Denis Fantinato

SUMÁRIO

Introdução

Fundamentação

Metodologia

Resultados

Conclusão

Referências

INTRODUÇÃO

- Supervisionado
- Não Supervisionado
- Por Reforço (RL)




Figura 1. Paradigmas de aprendizado: supervisionado, não supervisionado e por reforço.

INTRODUÇÃO

USO DE REDES PROFUNDAS MNIH ET AL. [1]




Figura 2. Arquitetura DQN aplicada a jogos Atari [1].

INTRODUÇÃO

PLANO DE INFORMAÇÃO E INFORMATION BOTTLENECK





Figura 3. Plano de Informação na formulação clássica [2]. **Figura 4.** Adaptações para RL via Information Bottleneck [3, 4].

OBJETIVOS DA PESQUISA

- Objetivo geral: aprofundar a compreensão da dinâmica do aprendizado em RL a partir do plano de informação.
- Investigar o fluxo de informação na rede profunda durante o aprendizado do agente.
- Analisar trajetórias no plano de informação e identificar possíveis estágios do aprendizado.
- Propor variação do plano de informação para RL sem depender de rótulo explícito.
- Avaliar efeito de topologias distintas em diferentes ambientes.

FUNDAMENTAÇÃO

BASES TEÓRICAS

- Redes neurais artificiais: Perceptron e MLP [5].
- Aprendizado por reforço: funções valor, actor-critic e PPO [6, 7, 8].
- Teoria da informação: entropia, divergência KL e informação mútua [9].
- Information Bottleneck e plano de informação [2, 10].

FUNDAMENTAÇÃO

REDES NEURAIS ARTIFICIAIS




Figura 5. Perceptron [5].




Figura 6. MLP e representação em camadas [5].

FUNDAMENTAÇÃO

APRENDIZADO POR REFORÇO




Figura 7. Formulação do problema de RL [7].





Figura 8. Objetivo do PPO [8].

FUNDAMENTAÇÃO

TEORIA DA INFORMAÇÃO




Figura 9. Entropia, divergência KL e informação mútua [9].





Figura 10. Plano de Informação [2].

METODOLOGIA PROPOSTA

1. Agente PPO com topologia padrão de duas camadas intermediárias (32 neurônios cada).
2. Topologias alternativas com uma e três camadas para comparação.
3. Estimação de informação mútua com NPEET/KNN [11].
4. Ambientes: Pendulum, Acrobot, MountainCar e CartPole.
5. Cada experimento executado por 10^6 passos.

METODOLOGIA

AGENTE E IMPLEMENTAÇÃO



$$(n_X, 32, 32, n_Y)$$

Figura 11. Topologia de rede utilizada nos experimentos.



Figura 12. Implementação com Stable-Baselines3.


METODOLOGIA

FLUXO DE TREINAMENTO E ESTIMAÇÃO

- Interação com ambiente até preencher buffer de 2048 passos.
- Pausa da coleta e atualização das redes ator/crítico por 10 épocas.
- Estimação de informação mútua a cada época de atualização.
- Reinício do buffer e continuação da interação com política atualizada.

METODOLOGIA

ESTIMAÇÃO DE INFORMAÇÃO MÚTUA



RESULTADOS PRINCIPAIS

- Observação de fases distintas no processo de aprendizado.
- Tendências no plano de informação indicam potencial convergência.
- Diferenças entre topologias afetam dinâmica e estabilidade.
- Flutuações na IM estimada são inerentes ao método de estimação.

CONCLUSOES E CONTRIBUICOES

- O plano de informação é uma métrica alternativa promissora para análise em RL.
- Há evidências de estágios distintos ao longo do treinamento.
- Generalização dos padrões ainda requer investigação aprofundada.
- As trajetórias no plano de informação trazem sinais úteis para diagnóstico do aprendizado.

PROXIMOS PASSOS

- Expandir análise para ambientes mais complexos da Gymnasium.
- Comparar com DQN, SAC e TD3.
- Investigar impacto de hiperparâmetros e topologias na trajetória da IM.
- Explorar uso da IM como critério de convergência do agente.

REFERÊNCIAS I

- [1] V. Mnih et al., “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [2] R. Shwartz-Ziv and N. Tishby, “Opening the black box of deep neural networks via information,” *arXiv preprint arXiv:1703.00810*, 2017.
- [3] X. Lu et al., “Dynamics generalization via information bottleneck in deep reinforcement learning,” *arXiv preprint arXiv:2008.00614*, 2020.
- [4] J. Fan and W. Li, “Dribo: Robust deep reinforcement learning via multi-view information bottleneck,” in *Proceedings of Machine Learning Research*, 2022.
- [5] S. S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. New York: Prentice-Hall, 2009.
- [6] S. J. Russell, P. Norvig, and E. Davis, *Artificial Intelligence: A Modern Approach*, 3rd ed. Upper Saddle River: Prentice Hall, 2010.
- [7] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*. Cambridge, MA: MIT Press, 1998.
- [8] J. Schulman et al., “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [9] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Hoboken, N.J.: Wiley-Interscience, 2006.

REFERÊNCIAS II

- [10] N. Tishby and N. Zaslavsky, "Deep learning and the information bottleneck principle," in *2015 IEEE Information Theory Workshop (ITW)*, Jerusalem, Israel: IEEE, 2015.
- [11] A. Kraskov, H. St"ogbauer, and P. Grassberger, "Estimating mutual information," *Physical Review E*, vol. 69, no. 6, 2004.